Travaux Pratiques – Modèles Statistiques en Santé
Manipulations de données cliniques et Tests d'hypothèses sous R

Master Mathématiques – Science des Données / Santé

Octobre 2026

1 Objectifs du TP

L'objectif de ce TP est de mettre en pratique les concepts fondamentaux de la recherche reproductible, de la statistique descriptive univariée et des tests d'hypothèses de position (*Student* et *Mann-Whitney-Wilcoxon*), en s'appuyant sur un véritable essai clinique publié dans le *New England Journal of Medicine* (Elmunzer et al., 2012).

1.1 Contexte scientifique

L'étude porte sur la prévention de la pancréatite aiguë après une cholangiopancréatographie rétrograde endoscopique (CPRE), une procédure d'intervention biliaire à haut risque. Cet essai clinique randomisé en double aveugle évalue l'efficacité de l'indométacine rectale (AINS) par rapport à un placebo.

2 Partie 0 : Lecture d'article

1. Dans l'article, repérer la structure : quelles sont les grandes parties ?
2. Dans la partie *methods*, auelles méthodes statistiques sont listées ?
3. Dans la partie *results* et ou dans les figures, peut on retrouver des tests statistiques ? Si oui, lesquels ? eut-on justifier les choix de ces tests (hypothèses de tet, distribution de la statisitque de test, etc) ?

3 Partie 1 : Préparation de l'environnement et Reproductibilité

Conformément aux bonnes pratiques de recherche reproductible présentées au cours :

1. Créez un nouveau projet sous RStudio nommé `TP_Biostat_Clinique`.
2. Initialisez un dépôt `git` local dans votre dossier de travail et créez un fichier R Markdown (`.Rmd`) ou Quarto (`.qmd`) qui contiendra l'intégralité de vos analyses textuelles et vos blocs de code.
3. Installez et chargez le package `medicaldata` afin de pouvoir importer le jeu de données de l'essai clinique nommé `indo_rct`.

4 Partie 2 : Exploration descriptive univariée

Avant d'appliquer tout test statistique, il est primordial de regarder et comprendre la distribution de nos données.

1. Donnez la taille de l'échantillon global ainsi que le nombre de patients inclus dans le groupe traitement (`indomethacin`) et le groupe contrôle (`placebo`).

2. Isoler la variable d'intérêt quantitative `age`. Calculez séparément pour chaque groupe de traitement les statistiques descriptives de base (moyenne, écart-type, médiane, quartiles).
3. Réalisez un graphique adapté (de type boxplot) permettant de visualiser et de comparer visuellement la distribution de l'âge entre les deux bras de l'étude. Commentez.

5 Partie 3 : Tests d'hypothèses de position (Student vs Wilcoxon)

On souhaite vérifier si la randomisation a été efficace en s'assurant que l'âge des patients est comparable entre le groupe placebo et le groupe indométacine (absence de biais de confusion).

1. **Formulation mathématique :** Énoncez clairement l'hypothèse nulle H_0 et l'hypothèse alternative H_1 associées à cette question de recherche. S'agit-il d'un test unilatéral ou bilatéral ?
2. **Vérification des postulats :**
   — Évaluez graphiquement la normalité de la variable `age` dans chaque groupe à l'aide de graphiques de type QQ-plot.
   — Réalisez un test de Shapiro-Wilk afin de tester formellement la normalité de la distribution au seuil $\alpha = 0.05$.
3. **Choix et exécution du test :** Au vu des résultats précédents, déterminez s'il est plus rigoureux d'appliquer un test paramétrique (t-test de Student) ou un test non-paramétrique (Mann-Whitney-Wilcoxon). Exécutez le test choisi sous R.
4. **Interprétation clinique :** Interprétez la *p-value* obtenue au regard du seuil de significativité $\alpha = 0.05$. Que concluez-vous quant à l'équilibrage des groupes par la randomisation ?